Descubrimiento de Leyes Físicas mediante Machine Learning

Jorge Acebes Hernández Andrés López Serna Lorenzo Ji

Universidad Autónoma de Madrid
Grado en Física

Estructura de la presentación

1. **Fundamentos**
   - Motivación y contexto
   - Diseño experimental
   - Criterio de evaluación
2. **Modelos**
   - Redes neuronales (MLP)
   - Métodos simbólicos: PySINDy, GPLearn, PySR, QLattice
3. **Resultados**
   - Generalización fuera de dominio (OOD)
   - Recuperación de leyes físicas
4. **Conclusiones**

Motivación: ¿por qué regresión simbólica?

Paradigma clásico:

- Teoría $\longleftrightarrow$ validación empírica
- Requiere intuición previa del físico

Alternativa data-driven:

- Inferencia directa de estructuras analíticas
- Datos abundantes + capacidad de cómputo

Objetivo del trabajo

Comparar distintos modelos de ML en su capacidad de **redescubrir leyes físicas** a partir de datos sintéticos con diferentes niveles de ruido.

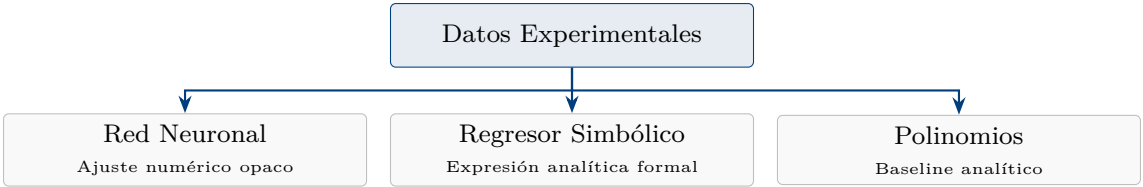

Leyes físicas estudiadas y protocolo de datos

Ley	Expresión
Coulomb	$F = q_1 q_2 / r^2$
Oscilador armónico	$F = -x$
3ª ley de Kepler	$T = r^{3/2}$
Gases ideales	$P = nT/V$
Dilatación temporal	$t' = t/\sqrt{1-v^2}$
Rango proyectil	$R = v_0^2 \sin 2\theta$
Decaimiento rad.	$N = e^{-\lambda t}$
Enfriamiento Newton	$\Delta T = 1 + e^{-kt}$
Entropía Boltzmann	$S = \ln \Omega$

Generación de datos:

- 10^4 muestras por ley, variables uniformes
- Constantes adimensionalizadas ($= 1$)
- Split: 60 %/20 %/20 %
- Ruido gaussiano proporcional: $y_{\text{noisy}} = y_{\text{exact}} + \varepsilon \cdot \sigma_y \cdot \mathcal{N}(0, 1)$

Tres regímenes de ruido:

$\varepsilon = 0$	Determinista
$\varepsilon = 0.01$	Ruido débil
$\varepsilon = 0.1$	Ruido fuerte

Evaluación OOD

Para cada ley se genera un conjunto adicional **fuera del rango de entrenamiento** (OOD) para evaluar capacidad de extrapolación real, no la interpolación geométrica.

Criterio de evaluación: clasificación por MSE

Categoría	Rango de MSE	Interpretación
Exacta	$\text{MSE} < 10^{-20}$	Expresión analítica recuperada
Precisa	$10^{-20} \leq \text{MSE} < 10^{-4}$	Topología correcta, constantes desajustadas
Aproximada	$10^{-4} \leq \text{MSE} < 10^{-2}$	Forma funcional parcialmente correcta
Incorrecta	$\text{MSE} \geq 10^{-2}$	No captura la física subyacente

- Métrica reportada en **espacio físico original** (sin escalado)
- Se evalúa tanto en dominio de entrenamiento (IOD) como fuera (OOD)
- El MSE IOD bajo no es suficiente: **el test real es OOD**

Modelos de perceptrones multicapa (MLP)

Objetivo: aproximar relaciones no lineales complejas

- Implementación: `PyTorch`
- Optimización: `Adam`
- Entrenamiento por batches (train / validation)

Arquitectura	Estructura de Capas	Activación	Regularización	Resultado
MLP Estándar	$d_{\text{in}} \to 64 \to 64 \to 1$	SiLU	Ninguna	Alta capacidad
MLP Disperso	$d_{\text{in}} \to 16 \to 16 \to 1$	tanh	$\mathcal{L}_{L_1} = \lambda \sum_i \lvert w_i \rvert$	Modelo simple
MC Dropout	$d_{\text{in}} \to 32 \to 32 \to 1$	ReLU	Dropout ($p = 0.2$)	Modelo robusto

Regresión polinómica

Idea clave: regresión lineal aplicada sobre una **base expandida** de términos polinómicos

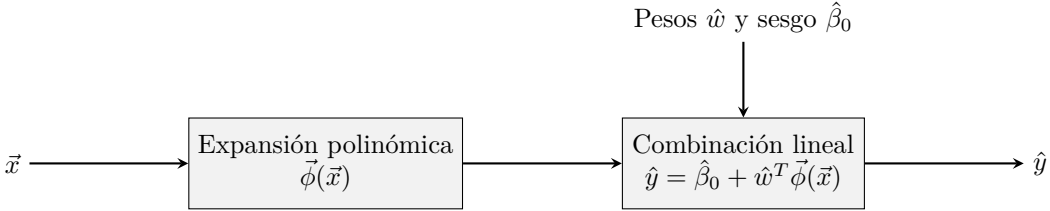

- $\vec{\phi}(\vec{x})$: Expansión polinómica a partir del vector de entrada $\vec{x}$: $\{x_i,\ x_i x_j,\ x_i^2,\ x_i x_j^2,\ ...\}$

Limitaciones

- Ampliación de la base polinómica al crecer $\vec{x}$ $\rightarrow$ Difícil interpretación física
- No captura funciones trascendentes e irracionales (exp, log, raíces) $\rightarrow$ Aproximación puramente local

PySINDy (Sparse Identification)

Idea clave: combinación lineal **dispersa** de funciones candidatas

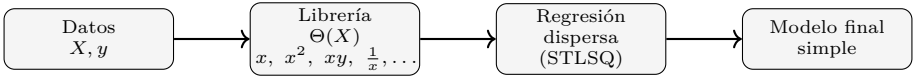

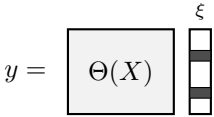

- Librería fija: polinomios + términos racionales
- Selección automática de pocos términos (*sparsity*)
- Control de complejidad (parsimonia)
- Limitación: depende de la librería

GPLearn (Programación genética)

Idea clave: evolución de expresiones matemáticas como árboles sintácticos

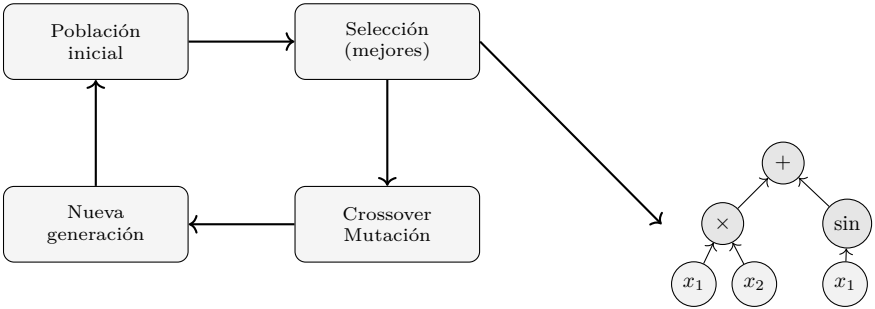

Características clave

- Expresiones como árboles (operadores + variables)
- Optimiza: MSE + penalización por complejidad (parsimonia)
- Riesgo: *bloat* (crecimiento excesivo del árbol)

PySR: Regresión simbólica evolutiva

Idea: algoritmos evolutivos para descubrir expresiones matemáticas a partir de datos.

Algoritmo evolutivo:

- Poblaciones tipo islas → evolución paralela
- Mutación, cruce y simplificación
- Selección por torneo

Criterio: `model_selection = "best"`

- Baja pérdida + baja complejidad

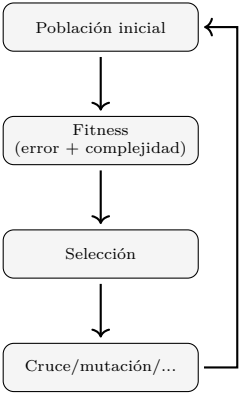

Evolución + frontera de Pareto

QLattice (modelo probabilístico de grafos)

Idea: aprender una distribución de probabilidad, $P(G)$, sobre grafos.

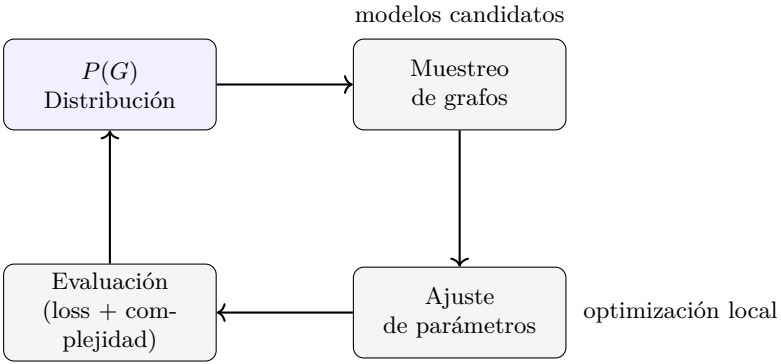

Ventaja clave:

El método de actualización interativa de $P(G)$ sobre gráficos favorece la generación de modelos precisos pero simples (principio de parsimonia)

Optuna (Optimización de hiperparámetros)

Idea clave: probar configuraciones y quedarse con la mejor

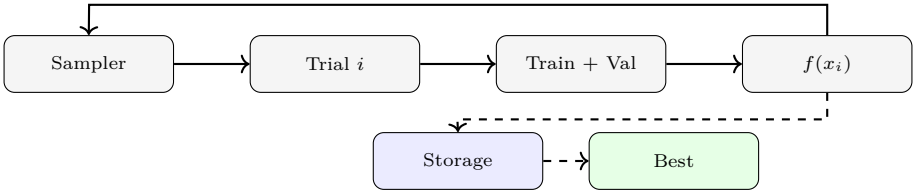

- Muestreo no sesgado mediante `RandomSampler`
- Evaluación: $f(\mathbf{x}_i) = \mathbb{E}[\mathrm{MSE}_{\mathrm{val}}] + \alpha\, \sigma_{\mathrm{MSE}_{\mathrm{val}}}$
- Historial de trials $\rightarrow$ Selección del mejor

Resultados: Desempeño en Dominio Interpolativo (IOD)

Observación Fundamental

La topología de todos los modelos posee suficiente capacidad para minimizar el error en el dominio de entrenamiento. El desempeño local **no garantiza** validez física.

	L. de Coulomb (r^{-2})		**L. de Kepler** ($r^{3/2}$)	
Arquitectura	$\mathrm{MSE}_{\mathrm{IOD}}$	$\mathrm{MSE}_{\mathrm{OOD}}$	$\mathrm{MSE}_{\mathrm{IOD}}$	$\mathrm{MSE}_{\mathrm{OOD}}$
Polinómico	$6.54 \cdot 10^{-3}$	$\sim 10^{6}$	$3.45 \cdot 10^{-7}$	$\sim 10^{4}$
MLP Estándar	$2.03 \cdot 10^{-4}$	$5.06 \cdot 10^{-1}$	$2.01 \cdot 10^{-6}$	$\sim 10^{2}$
PySR	$3.14 \cdot 10^{-13}$	**Exacto** (0)	$4.04 \cdot 10^{-11}$	$\sim 10^{-8}$
GPLearn	$3.01 \cdot 10^{-13}$	**Exacto** (0)	$3.41 \cdot 10^{-13}$	$\sim 10^{-30}$

Resultados OOD: Convergencia Topológica

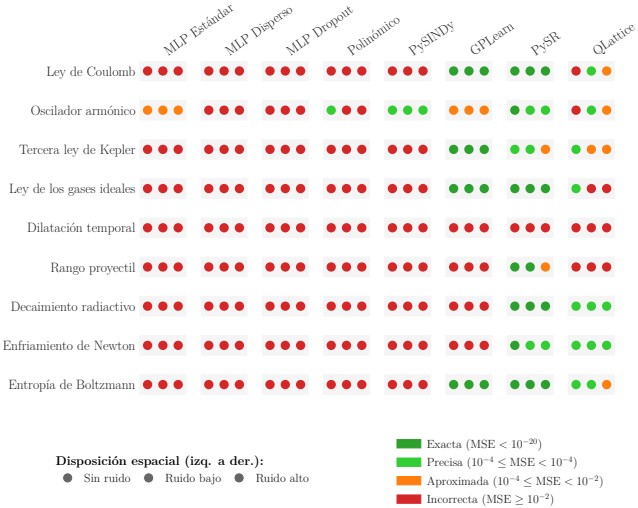

Análisis de Expresiones Recuperadas (Límite Determinista)

		Redes Neuronales				Regresores Simbólicos			
Ley Física	Forma Analítica	Estándar	Dispersa	Dropout	Polinomial	PySINDy	GPLearn	PySR	QLattice
Ley de Coulomb	q_1q_2/r^2	–	–	–	$-0.0382q_1^3 - 0.07292q \ldots$	$-1.037 + 6.685 \times 10^{-1} \ldots$	q_1q_2/r^2	$q_1q_2/(r^2)$	$2.042(-0.3664 + 0.9505/(0.4956 \ldots$
Oscilador armónico	$-x$	–	–	–	$2.52 \times 10^{-8}x^5 - 1.3 \ldots$	$-x$	$-0.995x$	$-x - x + x$	$-7.376(1.356x + 0.002145) \ldots$
Tercera ley de Kepler	$r^{3/2}$	–	–	–	$-0.005556r^5 + 0.05599r^4 \ldots$	$-5.211 \times 10^{-2} + 5.788 \ldots$	$r^{3/2}$	$r^{1.4999973}$	$-1.481(-0.5112r - 0.008606) \ldots$
Ley de los gases ideales	nT/V	–	–	–	$0.009562T^5 - 0.0006943T^4 \ldots$	$-5.103 \times 10^{-3} + 5.501 \ldots$	Tn/V	Tn/V	$-0.7828(4.93T + 0.0003735)(\ldots$
Dilatación temporal	$t/\sqrt{1-v^2}$	–	–	–	$-0.01782v^5 + 0.2808t^4v \ldots$	$2.415 \times 10^{-1} + 5.793 \ldots$	$t(v+1)$	$t(1.6901535 + 1/\cos(v^{1.3647355} \ldots$	$-2.098(1.039 - 0.7927v)(2.13 \ldots$
Rango proyectil	$v_0^2\sin(2\theta)$	–	–	–	$-0.006502\theta^5 + 2.152 \ldots$	$-6.142 \times 10^{-1} + 1.266 \ldots$	$v_0^{3/2}\sqrt{\log(\theta} \ldots$	$v_0^2\sin(\theta+\theta)$	$-15.61\exp(-2.0(0.142 - 0.12 \ldots$
Decaimiento radiactivo	$e^{-\lambda t}$	–	–	–	$-0.0279\lambda^5 + 0.07706 \ldots$	$9.853 \times 10^{-1} + 1.136 \ldots$	$\cos(\sqrt{t})$	$\exp(\lambda)^{-t}$	$\exp((1.303 \times 10^{-6} - 0. \ldots$
Enfriamiento de Newton	$1 + e^{-kt}$	–	–	–	$-0.03169k^5 + 0.0738k^4t \ldots$	$2.002 + 1.984 \times 10^{-1} \ldots$	1.36612021857923	$\exp(-kt) + 1.0$	$\exp((1.272 \times 10^{-5} - 0. \ldots$
Entropía de Boltzmann	$\ln(\Omega)$	–	–	–	$0.00011723^5 - 0.003861 \ldots$	$1.737 + 8.828 \times 10^{-2} \ldots$	$\log(\Omega)$	$\log(\Omega)$	$\log(0.408\Omega - 9.859 \ldots$

Exacta (MSE $< 10^{-20}$) Precisa ($10^{-20} \leq$ MSE $< 10^{-4}$) Aproximada ($10^{-4} \leq$ MSE $< 10^{-2}$) Incorrecta (MSE $\geq 10^{-2}$)

Discusión Analítica

Aproximadores Locales (MLP/Pol.)

- Excelentes en el colector de datos de entrenamiento.
- Divergencia asintótica fuera de dominio (colapso OOD).
- Carecen de invarianzas físicas intrínsecas o mecanismos para inferir la simetría de la ecuación.

Regresores Simbólicos

- Convergencia al límite analítico: $\mathrm{MSE}_{\mathrm{OOD}} \approx 0$ si se halla la topología subyacente.
- **PySR** exhibe robustez máxima frente a mínimos locales.
- **GPLearn** y **QLattice** penalizan fuertemente ante bases de operadores incompletas.

Impacto Estocástico (Ruido)

La adición de ruido $\varepsilon > 0$ introduce desviaciones en los tensores de constantes multiplicativas, pero **preserva la topología funcional** hallada por los algoritmos evolutivos en el 90 % de los casos.

Conclusiones

Jerarquía de Inferencia Asintótica

$$\textbf{PySR} \succ \text{GPLearn} \approx \text{QLattice} \succ \text{PySINDy} \succ \text{Polinomial} \gg \text{Redes Neuronales}$$

1. La inferencia de la estructura analítica formal es un requisito estricto para garantizar predictibilidad física fuera del dominio de entrenamiento.
2. La parsimonia matemática actúa como el regularizador natural fundamental en el espacio funcional.
3. Los algoritmos evolutivos (PySR) logran extraer la ley subyacente de los observables minimizando el sesgo teórico impuesto *a priori*.

Conclusiones

Jerarquía de Inferencia Asintótica

$$\textbf{PySR} \succ \text{GPLearn} \approx \text{QLattice} \succ \text{PySINDy} \succ \text{Polinomial} \gg \text{Redes Neuronales}$$

1. La inferencia de la estructura analítica formal es un requisito estricto para garantizar predictibilidad física fuera del dominio de entrenamiento.
2. La parsimonia matemática actúa como el regularizador natural fundamental en el espacio funcional.
3. Los algoritmos evolutivos (PySR) logran extraer la ley subyacente de los observables minimizando el sesgo teórico impuesto *a priori*.

`Código accesible en: https://github.com/JorgeAcebes/symbolic-physics-discovery.git`

[Backup] ¿Por qué RandomSampler en lugar de TPE?

TPE (*Tree-structured Parzen Estimator*) es el algoritmo por defecto de `Optuna`: modela la densidad de probabilidad de los hiperparámetros condicionada al historial de trials.

Problema en este contexto:

- Espacio de hiperparámetros de alta dimensión
- Número reducido de iteraciones por presupuesto computacional
- TPE necesita muchas evaluaciones para construir un modelo de densidad fiable

RandomSampler como baseline

- Muestreo uniforme $x_i \sim \mathcal{U}(\mathcal{X})$, independiente del historial
- Exploración insesgada
- Determinista: permite comparación reproducible entre modelos y leyes
- En régimen de pocos trials, comparable en rendimiento a TPE

[Backup] ¿Por qué GPLearn no recupera exponenciales?

El espacio funcional de GPLearn está definido por:

$$\{+,\ -,\ \times,\ \div,\ \wedge, \sin x,\ \cos x,\ x^{-1},\ \sqrt{x},\ \ln x\}$$

No incluye e^x ni composiciones que generen exponenciales.

Para $N = e^{-\lambda t}$, GPLearn intenta aproximar la exponencial con sus operadores disponibles:

- $\cos(\sqrt{t})$ minimiza el MSE local dentro del rango
- Fuera del dominio, la aproximación diverge
- Resultado: $\mathrm{MSE}_{\mathrm{OOD}} \approx 0.29$, clasificado como **incorrecto**

Sesgo del espacio funcional

Esta limitación no refleja una debilidad del algoritmo evolutivo en sí, sino una **decisión de diseño** sobre el diccionario de operadores.

Incluyendo e^x en el espacio funcional, GPLearn recuperaría las leyes exponenciales con la misma eficacia con que recupera las logarítmicas.

[Backup] ¿Por qué ningún modelo recupera la dilatación temporal?

$$t' = \frac{t}{\sqrt{1 - v^2}}$$

Problema de muestreo:
Con $v \sim \mathcal{U}(0, 1)$, la mayoría de puntos cae en la región $v \ll 1$ donde $t' \approx t$. La curvatura característica de la función solo se manifiesta para $v \to 1$, región sistemáticamente subrepresentada.

Consecuencia:

- Los modelos aprenden $t' \approx t$ con pequeñas correcciones
- La topología funcional real (raíz cuadrada en denominador) no es detectada
- PySR aproxima: $t(v + 1)$ o $t/\cos(v^{1.36})$

Solución propuesta

Un muestreo adaptativo con mayor densidad para $v \in [0.8, 1)$ proveería la información necesaria para identificar la singularidad.

Alternativamente, aumentar el número de épocas en PySR podría eventualmente encontrar la expresión exacta, a costa de mayor tiempo computacional.

Conclusión: limitación del *protocolo experimental*, no de los algoritmos.

[Backup] ¿Qué ventaja real ofrece PySR frente a GPLearn?

Diferencias algorítmicas clave:

- PySR usa **múltiples islas** (poblaciones paralelas) con migración por torneos $\rightarrow$ evita mínimos locales
- GPLearn usa una única población con presión de selección por torneo
- PySR construye un **frente de Pareto global** (complejidad vs. error) $\rightarrow$ selección óptima explícita
- PySR delega el cómputo pesado a **Julia**: mayor velocidad por generación

Espacio de operadores:

Operador	GPLearn	PySR
$+, -, \times, \div$	✓	✓
$\sin x, \cos x$	✓	✓
$\ln x, \sqrt{x}$	✓	✓
e^x	—	✓
x^a	✓	✓

El espacio más rico de PySR, combinado con la topología multi-isla, explica su ventaja en leyes con composiciones no triviales.

[Backup] PySR: Criterio de Selección de Modelos

Frontera de Pareto: Complejidad vs. Error

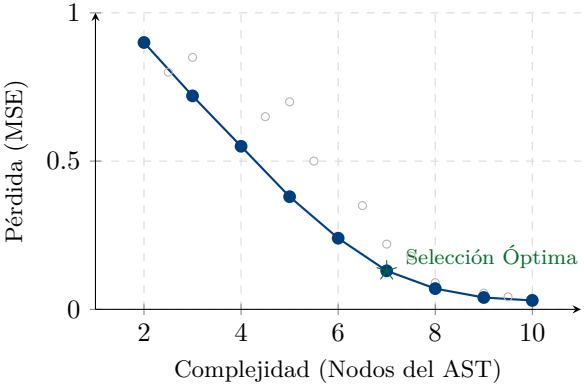

La ecuación retornada es el vértice que maximiza la ganancia marginal de precisión por unidad de complejidad añadida.

[Backup] Limitaciones del estudio

1. **Espacio de operadores heterogéneo entre modelos**
   GPLearn carece de operadores exponenciales; QLattice, de sinusoidales. Las diferencias de rendimiento reflejan decisiones de diseño, no solo la calidad del algoritmo.

2. **Hiperparámetros promediados**
   Un único conjunto de hiperparámetros por modelo (media sobre `Optuna` por ley) es subóptimo para cada dataset particular; puede sesgar la comparativa.

3. **Ausencia de análisis de varianza entre semillas**
   Los resultados son puntuales: sin intervalos de confianza no es posible afirmar significación estadística de las diferencias observadas.

4. **Muestreo uniforme inadecuado para no linealidades locales**
   Leyes como la dilatación temporal tienen comportamiento relevante concentrado en una región. Un muestreo adaptativo mejoraría el condicionamiento del problema.

[Backup] Curva de loss para MLP Estándar (Ley de Coulomb)

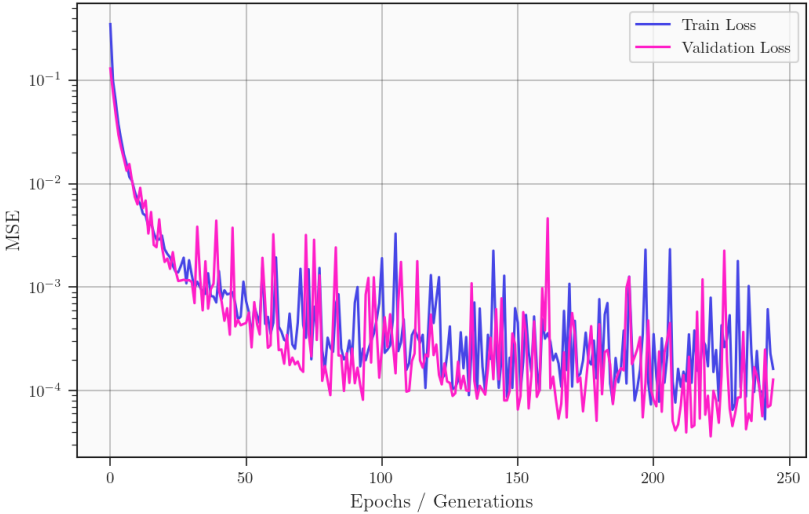

[Backup] Curva de loss para QLattice (Ley de Coulomb)

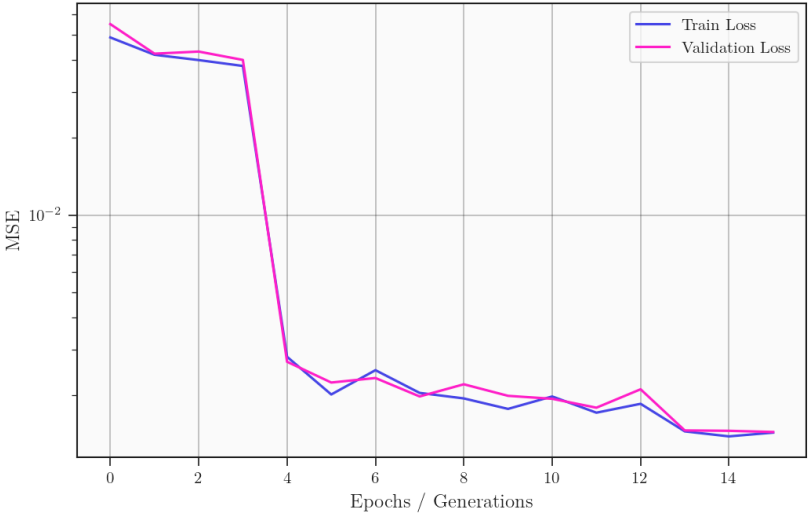

[Backup] MSE OOD (Tercera Ley de Kepler)

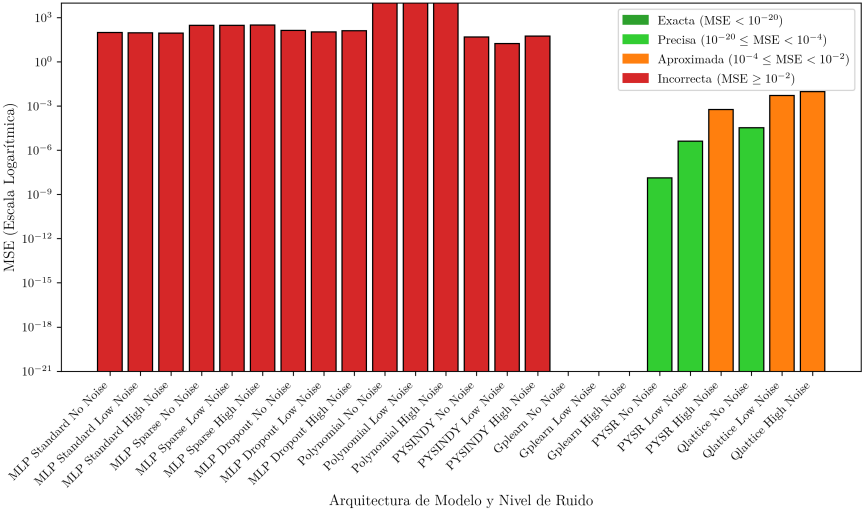

[Backup] MSE OOD (Oscilador Armónico)

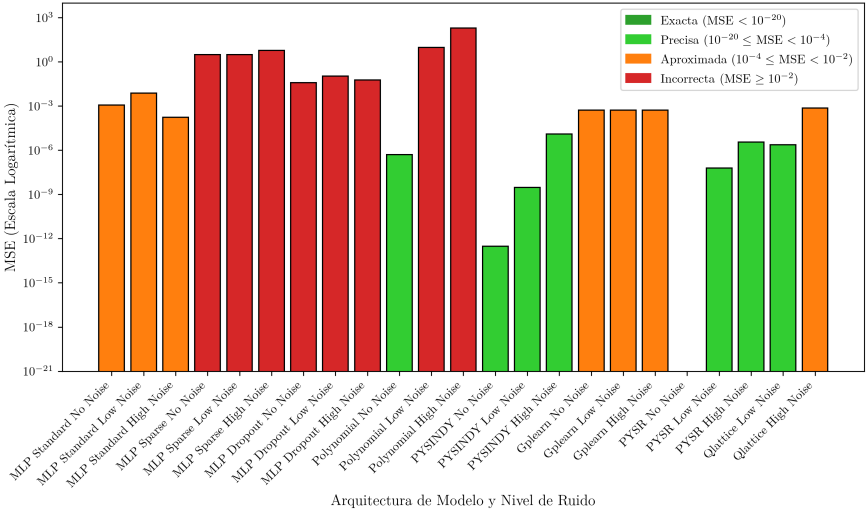

[Backup] Análisis de Expresiones Recuperadas (Ruido Bajo)

		Redes Neuronales				Regresores Simbólicos			
Ley Física	Forma Analítica	Estándar	Dispersa	Dropout	Polinomial	PySINDy	GPLearn	PySR	QLattice
Ley de Coulomb	$q_1 q_2/r^2$	–	–	–	$-0.03695q_1^2 - 0.07018q \ldots$	$-1.036 + 6.672 \times 10^{-1} \ldots$	$q_1 q_2/r^2$	$q_1 q_2/(r^2)$	$2.086(0.3505q_1 + 0.001896) \ldots$
Oscilador armónico	$-x$	–	–	–	$0.0001097x^3 + 9.195 \ldots$	$-x$	$-0.995x$	$-x - 0.00025102496$	$-0.9994x - 0.001266$
Tercera ley de Kepler	$r^{3/2}$	–	–	–	$-0.006601r^5 + 0.06382r^4 \ldots$	$-1.259 \times 10^{-1} + 8.277 \ldots$	$r^{3/2}$	$r^{1.5000477}$	$2.811(0.4257r - 0.07997) \ldots$
Ley de los gases ideales	nT/V	–	–	–	$0.03444T^5 - 0.01838T^4V \ldots$	$-9.143 \times 10^{-3} + 3.459 \ldots$	Tn/V	Tn/V	$-2.466(0.003451 - 0.1432T)(0 \ldots$
Dilatación temporal	$t/\sqrt{1-v^2}$	–	–	–	$-0.01266t^5 + 0.2917t^4v \ldots$	$2.416 \times 10^{-1} + 5.745 \ldots$	$t(v+1)$	$t/(\cos(v1.5881233)^{0.4212728})$	$0.7705t + 0.002551 - 0.6356(\ldots$
Rango proyectil	$v_0^2 \sin(2\theta)$	–	–	–	$0.00052539^5 + 2.203 \ldots$	$-6.159 \times 10^{-1} + 1.256 \ldots$	$v_0^{3/2}\sqrt{\log(\theta} \ldots$	$v_0^2 \sin(\theta + \theta)$	$17.86 \exp(-2.0(0.328v_0 \ldots$
Decaimiento radiactivo	$e^{-\lambda t}$	–	–	–	$-0.02738\lambda^5 + 0.07748 \ldots$	$9.856 \times 10^{-1} + 1.13 \ldots$	$\cos(\sqrt{t})$	$\exp(t)^{-\lambda}$	$0.9995 \exp((0.0008908 - 0.5667 \ldots$
Enfriamiento de Newton	$1 + e^{-kt}$	–	–	–	$-0.0308k^5 + 0.07308k^4t \ldots$	$2.002 + 1.995 \times 10^{-1} \ldots$	1.36612021857923	$\exp(k(-1.0004783))^t + 1.000121$	$\exp((0.000273 - 0.5565t)(1.7 \ldots$
Entropía de Boltzmann	$\ln(\Omega)$	–	–	–	$0.00011663^5 - 0.003842 \ldots$	$1.738 + 8.819 \times 10^{-2} \ldots$	$\log(\Omega)$	$\log(\Omega)$	$1.001 \log(0.27682\Omega - 0.00 \ldots$

Exacta (MSE $< 10^{-20}$) Precisa ($10^{-20} \leq$ MSE $< 10^{-4}$) Aproximada ($10^{-4} \leq$ MSE $< 10^{-2}$) Incorrecta (MSE $\geq 10^{-2}$)

[Backup] Análisis de Expresiones Recuperadas (Ruido Alto)

		Redes Neuronales				Regresores Simbólicos			
Ley Física	Forma Analítica	Estándar	Dispersa	Dropout	Polinomial	PySINDy	GPLearn	PySR	QLattice
Ley de Coulomb	$q_1 q_2 / r^2$	–	–	–	$-0.04889q_1^2 - 0.09459q_1 \ldots$	$-9.682 \times 10^{-1} + 2.919 \ldots$	$q_1 q_2 / r^2$	$q_1 q_2 / (r^2)$	$2.861(0.8354q_1 + 0.002987) \ldots$
Oscilador armónico	$-x$	–	–	–	$-0.000635x^5 + 0.00138x^4 \ldots$	$-9.992 \times 10^{-1} x$	$-0.995x$	$-x + 0.0019095138$	$-0.9964x + 0.01087$
Tercera ley de Kepler	$r^{3/2}$	–	–	–	$-0.00689r^5 + 0.07283r^4 \ldots$	$-5.532 \times 10^{-2} + 5.813 \ldots$	$r^{3/2}$	$r^{1.5005707}$	$2.328\sqrt{0.2723r - 0.02623} \ldots$
Ley de los gases ideales	nT/V	–	–	–	$0.04708T^5 + 0.04781T^4V \ldots$	$4.225 \times 10^{-2} + 4.059 \ldots$	Tn/V	Tn/V	$-1.513(0.4255V - 2.057)(4.18 \ldots$
Dilatación temporal	$t/\sqrt{1-v^2}$	–	–	–	$-0.17t^5 + 0.4091t^4v \ldots$	$2.438 \times 10^{-1} + 5.981 \ldots$	$t(v+1)$	$t/\cos((v + 0.16311686)^2)$	$0.7697t - 0.8242(0.901t - 0. \ldots$
Rango proyectil	$v_0^2 \sin(2\theta)$	–	–	–	$-1.1539^5 + 2.237 \ldots$	$-7.959 \times 10^{-2} - 1.209 \ldots$	$v_0^{3/2}\sqrt{\log(\theta} \ldots$	$v_0^2 \sin(\theta 2.001247)$	$1.25(0.6304\theta + 0.1075) \ldots$
Decaimiento radiactivo	$e^{-\lambda t}$	–	–	–	$-0.03926\lambda^5 + 0.07949 \ldots$	$9.868 \times 10^{-1} + 1.124 \ldots$	$\cos(\sqrt{t})$	$\exp(\lambda)^{-t}$	$1.003\exp((1.602\lambda + 0.0 \ldots$
Enfriamiento de Newton	$1 + e^{-kt}$	–	–	–	$-0.02462t^5 + 0.06923k^4 \ldots$	$1.977 + 1.685 \times 10^{-1} \ldots$	1.36612021857923	$\exp(-kt) + 1.0000027$	$1.003\exp((0.8531k + 0.003694 \ldots$
Entropía de Boltzmann	$\ln(\Omega)$	–	–	–	$0.00010463^5 - 0.003543 \ldots$	$2.313 \times 10^{-3}\Omega + 2 \ldots$	$\log(\Omega)$	$\log(\Omega)$	$1.006\log(0.2613\Omega + 0.00 \ldots$

Exacta (MSE $< 10^{-20}$) Precisa ($10^{-20} \leq$ MSE $< 10^{-4}$) Aproximada ($10^{-4} \leq$ MSE $< 10^{-2}$) Incorrecta (MSE $\geq 10^{-2}$)